





AI レーダー月報：2026年5月

Agentの主戦場は「モデル性能」から「プロダクション・システム」へ


焦点の変化：「モデルは何ができるか」から「誰がシステム境界を統制するか」へ。
中核的問い：誰がランタイムを持ち、評価を定義し、フィードバックを再利用可能なワークフローに変えるのか。

焦点の変化：「モデルは何ができるか」から「誰がシステム境界を統制するか」へ。
中核的問い：誰がランタイムを持ち、評価を定義し、フィードバックを再利用可能なワークフローに変えるのか。

Model Capability Showcase



Runnable, Auditable, Reusable System




Agent Runtime: クラウド・インフラの新たな標準層


Chat Boxから**実行環境**へ: Sandbox、Memory、State、Gatewayが標準構成に。

プロトコル化: 独立したツール呼び出しから、スケーラブルなランタイムシステムへの進化。

代表例: Claude Code, LangChain stack, CoreWeave Sandboxes, Google Managed Agents, AWS AgentCore.



Evaluation & Recovery: 単体スコアから「システム監査」へ



評価の再定義:

リーダーボードから、失敗コストやトレース再現性を問うシステム評価台帳へ移行。

Task ID	成功率 (Success Rate)	タスク単価 (Unit Cost)	再試行 (Retries)	人間介入率 (HITL Rate)
TSK-092	98.5%	\$0.004	1	0.2%
TSK-104	99.1%	\$0.003	0	0.0%
TSK-127	97.8%	\$0.006	2	1.5%

Codex Workflow: 組織のデリバリー・システムへの統合

エンジニアリング・ワークフロー全体の参加者



役割の変化

「コード補完アシスタント」
からの脱却

測定基盤

価値は単独の生成ではなく、
レビュー、ビルドログ分析、リ
ポジトリ横断修正で測られる。

実践例


Braintrust customer loops,
GitHub Copilot metrics,
Cursor habits.

RAG / Data Layer: 「ベクトル検索」から 「権限とデータ品質」へ

検索だけでは不十分: ベクトル検索単体から、データシステム全体の総合問題へ。

ボトルネック: 資産の発見、業務語彙の衝突、コンテキスト予算の管理。


必須要件: 企業データ権限、データリネージ、文書解析、検証可能な引用。




Inference Economics: 常時稼働を支えるコスト構造の再定義

パラダイムシフト: 逐次API呼び出しから「決定論的タスクのSandbox外出し」によるコンテキスト節約へ。

Model calls APIs step by step



Programmatic Tool Calling



経済性の再評価: タスク単価、レイテンシ、キャッシュがプロダクト形状を決定。動向: DeepSeek価格改定、vLLM + Mooncake。

Organization Adoption: 「全自動の幻想」から 「方法論の構築」へ

導入の鍵: 「社員1人に1エージェント」の幻想を捨て、問題設定、品質レビュー、責任分界を再設計する。

組織記憶: チームの経験をテンプレート、プラグイン、自動チェック (Compound Engineering) として蓄積。

役割の変化: AI Engineer (長期的) / Forward Deployed Engineer (移行期) がキーロールに。

Workflow (組織)

Task (個人)




Compound
Engineering

Fantasy (全自動)

Method (方法論)

Governance: 物理世界と高責任領域への進出



Summary: The 2026 AI Paradigm Shift

項目 (Theme)	Before (2025～2026初頭)	Now (2026年5月現在)
Runtime	Chat UI / API	監査・再利用可能な Execution Environment
Evaluation	リーダーボードの単体スコア	失敗例・コストを含む System Audit
Code	開発環境でのコード補完	組織のデリバリーワークフローへの統合
Data (RAG)	ベクトルDBへの格納・検索	権限 (ACL)、リネージ、コンテキスト予算
Cost	トークン価格の単純比較	キャッシュ、Sandbox外出を含む推論経済性

次月のレーダー：継続追跡テーマ

