

智能体工程的 工业化转折点

AI 雷达月报：2026 年 7 月




[SYSTEM: ONLINE] | [DATA: 2026-07-01 to 2026-07-31]

竞争焦点已发生结构性迁移

THE PAST

模型能不能完成任务？

单次模型调用



The diagram for 'THE PAST' shows a simple linear flow. A blue circle on the left has an arrow pointing to a blue rectangle labeled '单次模型调用' (Single Model Call). Another arrow points from the right side of the rectangle to a blue circle on the right. The background is dark gray with some faint grid lines.

THE PRESENT


系统能否以可控成本持续交付可验证结果？

LLM

预算

审批

回滚



The diagram for 'THE PRESENT' shows a more complex system flow. It features four main components in orange boxes: 'LLM' at the top, '预算' (Budget) in the middle left, '审批' (Approval) in the middle right, and '回滚' (Rollback) at the bottom right. Arrows indicate the flow: from 'LLM' down to '预算', from 'LLM' right to '审批', from '预算' right to '审批', from '审批' down to '回滚', and from '回滚' left back to '预算'. There are also double arrows indicating feedback loops from '审批' back to 'LLM' and from '回滚' back to 'LLM'. The background is dark gray with some faint grid lines.

METRIC SHIFT

衡量口径之变

核心关注点已从 Token 单价，转向单位结果成本（Useful work per dollar）、恢复时间与副作用边界。

PROCUREMENT LOGIC

采购逻辑之变

模型、数据、工具与组织流程已无法剥离优化，必须作为完整工程栈整体部署。

演化脉络：三周内的系统级跃迁



重构 AI 技术栈：2026 年 7 月全景图

应用与治理层：超越软件界限


企业工作流度量、人类最终责任、物理 AI 连续感知与协作

中间件与运行层：确定性控制面


12-Factor Agent 运行时、MCP 技能供应链、Ontology 与幂等性记忆、评测控制回路

模型与计算层：服务效率底座

Useful work per dollar、推理效率优化 (DSpark)、万亿级开放权重模型



Agent 运行时：重新引入严肃软件工程



核心动作

将协调逻辑放回确定性代码，减少 Token 消耗并缩小不可预测面。

代表系统

Plano、Gemini Managed Agents、OpenWorker

设计原则

任务不再是单向生成，而是带 Checkpoint 和 Audit Log 的可恢复软件系统。

评测升级：从发布榜单到贯穿周期的控制回路



破除迷信：单次答案正确 $\neq$ 系统安全或产品可用。

控制回路：失败样本必须能重新送回训练、路由或权限策略中。

企业行动：为高价值 Agent 建立包含真实副作用、环境边界和人工验收记录的持续账本。

生态重组：算力效率与技能供应链

模型侧：算力与推理效率




Kimi K3 / Inkling: 万亿参数 (3T+) 开放权重, 百万上下文。

DeepSeek DSpark: 投机解码提升服务吞吐。

核心竞争向延迟、吞吐和成功任务成本倾斜。

工具侧：能力供应链与 MCP



Stitch Skills / mcp-use: 将设计与文档打包成可安装技能。

治理与安全：来源审查、最小权限（Scope Gate）、版本锁定与软件依赖同等重要。

结构性含义：重塑组织形态与物理空间

数字化企业

买多少账号 →
 workflow可重复度与责任转移

真正的价值来自明确的人类最终责任、隐私与权限设计。AI 采用正式进入预算、岗位重写和风险管理。

物理 AI

网页与代码生成 →
 连续感知、仿真与多体协作

难点不再是生成单一动作，而是从连续视频中发现偏差、恢复失败、共享空间状态。

范式转移：旧模型思维 vs. 新智能体系统

核心维度	早期 AI 范式	工业化 Agent 范式
核心成本指标	Token 单价与理论峰值算力	单位结果成本 (Useful work per dollar)
能力边界扩展	依赖复杂的 Prompt 工程	依赖技能供应链 (MCP) 与标准接口
异常与失败处理	报错后由用户点击重新生成	幂等性控制、显式状态回滚与人工介入
企业落地形态	购买软件账号席位 (Seats)	workflow 深度集成、角色重组与长期度量

下月雷达：四大高优关注点



成功任务成本

优化动作将从单一推理层向路由 (Routing)、缓存 (Cache) 和确定性编排转移。



评测账本

必须为每次版本变化建立任务集、环境和人工验收的持续账本，以区分模型回归与环境变化。



副作用边界

文件、网络等外部工具必须将批准、幂等性与撤销设为一等公民；Prompt 不再是权限边界。



技能溯源

随着 MCP 成为标准能力分发格式，其来源、版本依赖和测试证据将决定生产环境的安全性。