

AI Radar Weekly: The Engineering Blueprint

2026-04-20 — 2026-04-26

PHASE TRANSITION: PoC -> PRODUCTION
FOCUS: DEPLOYABILITY, GOVERNANCE, AGENTIC RUNTIME



主戦場は「スコア」から「デプロイ可能性」へ

1



能力・長文脈・推論コストの複合戦。GPT-5.5とDeepSeek V4が実運用コストの基準を再定義。

2



単純なVector RAGの限界。グラフ構造とスキーマ最適化による「Context Engineering」への進化。

3



Zero-Secret

「プロンプトでの防御」から脱却。GitHub Agentic Workflowが示す三層隔離とゼロトラスト設計。


4

Unlimited Tokens



ShopifyやDoorDashが実証する、個人ツールからの脱却。再現可能な評価基盤と標準ランタイムの構築。

モデル競争の新基準：Active ComputeとContextの費用対効果



オーディエンスへの示唆：オープン/クローズド問わず、MOE (Mixture of Experts) による「アクティブ計算量の最小化」と「長文脈の維持」がデプロイの必須条件に。

Agent Memoryの再構築：Vector RAGから「ECLパイプライン」へ


The Problem: Tasteful tokenmaxxing



人間向けのAPIスキーマをそのまま読ませると、推論の迷走走とトークン浪費が発生。

Supabase MCP接続: 1タスク 10.4M tokens (\$9.21) を消費

The Solution: Context Engineering



InsForge型の構造化バックエンドによる「状態・スキーマ・エラー」の最適化。単一のベクトル検索ではなく、関係層・グラフ層・ドメイン辞書の併用がマルチホップ推論を支える。

結果: トークン使用量を 3.7M (\$2.81) へ 2.8倍削減。
エラー起因の再試行は10回から0回へ。

本番運用の壁を越える：前提は「Agentは既に侵害されている」

Layer 3: Planning (計画層)

全てのWrite操作をバッファに溜め、型検証・件数制限・内容スキャンを経てから決定論的に反映 (Safe Outputs)。

Layer 2: Configuration (構成層)

ワークフロー記述を、権限制約が付与されたアクションへコンパイル。

Layer 1: Substrate (基盤層)

Dockerコンテナ隔離、Linux kernel syscall制限によるサンドボックス化。



Zero-Secret Agent



モデルは独立コンテナで稼働し、API Keyやトークンは外部のProxyのみが保持。機密パスはtmpfsで秘匿。


プロンプト制御ではなく、物理的な構造でシークレットを隔離する多層防御。

インフラと組織の相転移：個人ツールから「標準ランタイム」へ




AIの価値は「生成速度」から「再現可能なワークフローのオーケストレーション」へ。

Synthesis: 2026 Production AI Stack



Radar Targets: 来週の検証ポイントと実務への示唆



Target 1: 実務環境でのモデル選定の再評価

GPT-5.5とClaude系列をベンチマークではなく「実際のコーディングワークフロー（CLI、デスクトップ連携、組織トークン運用）」で比較検証せよ。

Target 2: Long-Context Agentの安定性テスト

DeepSeek V4、GLM-5.1、Kimi K2.6の10万トークン超のタスク継続性を監視。長時間の自律実行における「方針転換（Replan）」の精度が実用性を決める。



Target 3: インフラストラクチャ層の更新

バックエンド情報（スキーマやステータス）のAgent向け最適化（Context Engineering）を開始せよ。MCP UIウィジェットやトレーシング基盤の導入が、開発速度のボトルネックを解消する。

