



AI競争は「モデル単体の賢さ」から「本番環境でのシステム稼働とコスト統制」へと完全にシフトした。





主線①：ステートレスな対話から「Agent Runtime」の構築へ


The Chat Era




揮発性のセッション、限定的な文脈

The Agent Runtime

LangGraph / Cloudflare Durable Execution



実運用の差別化要因は「ツールの呼び出し能力」から、チェックポイント、監査、失敗復旧の制御可能性へと移行した。



Agent拡張の三層構造：接続・知識・資産化の分離

MCP (Model Context Protocol)

役割：リアルタイムなシステム・データへの接続



特徴：JSON-RPC、厳格なスキーマ、独立したランタイム



ガバナンス焦点：権限の境界線 (Permission Boundary) とセキュリティ




Skills

役割：再利用可能な作業知識のパッケージ



特徴：手順書、参照資料、ローカル処理の定義



ガバナンス焦点：Agentが必要な時に読み込む「特定タスクの振る舞い」の統制




Compound Engineering

役割：IDEやツールを跨いだ組織資産の構築



特徴：スクリプト、規約、複数スキルを束ねたワークフロー基盤



ガバナンス焦点：個人の効率化から組織的なデリバリー資産への転換




プラットフォームチームへの示唆：「何に接続するか」「何を許可するか」「経験をどう再利用するか」を混同せず、別々のレイヤーとして設計せよ。



主線②：オープンモデルの進化と「評価コスト」という新たな壁

SURFACE LINE: BASIC CAPABILITIES



● チャット性能と単発ベンチマーク

Qwen3.6 (27B)、Kimi K2.6、Grok 4.3。長文脈、低コスト、複数ツールの利用能力向上。

● プロダクション展開の真のコストと要件

● **Agent Orchestration:** Kimi K2.6による最大300の並列サブエージェントと4000ステップの自律実行。

● **1M Context Optimization:** DeepSeek V4に見られるAgentワークロード向けの計算量最適化。

● **Evaluation Bottleneck (Critical):** EvalEval Coalitionの報告。一度の高度なタスク評価に数千ドルのコスト。


評価パラダイムの転換：単一の報酬スコアへの依存から脱却せよ。GEPA（軌跡ベースの反射）、RULER（多軌跡ランキング）、BARRED（専用の小型評価モデル）による「Coarse-to-fine（粗から精）」戦略が必須。

主線③：推論の転換点と「AIコストの台帳管理」


SYSTEM TIME: 2024-19-27 14:45:35 UTC
STATUS: OPERATIONAL

COMPUTE METERS


GPU Prefill/Decode



CPU & Sandbox



DeepSeek V4 Cache Hit



RESOURCE ROUTING WATERFALL

定型タスク・高頻度処理

キャッシュヒットを狙った
安価なモデル (Flash階層)

複雑なプランニング

高性能モデル (Pro階層)
ヘルレーティング

結果：Agentワークフローのコストが「
精密な従量課金管理 (Ledger)」へと引き戻される。



Stripeのインサイト：「AI時代の不正リスクは『盗難カードによる決済』から『計算資源の乱用』へと拡大した」。トークン消費とキャッシュヒット率は、今や企業の利益率を左右する最重要KPIである。




主線④：物理世界との衝突と「現場の制約」

SYSTEM TIME: 2024-19-27 14:49:35 UTC
STATUS: OPERATIONAL

SYSTEM LEDGER

決済リスク検知 (Stripe Radar)

レイテンシ




1決済あたり100ms以内で1000以上の信号を処理。複雑なDeepモデルから、運用耐性とルールエンジン協調を重視したアーキテクチャへの回帰。

SYSTEM TELEMETRY

自動運転 (Wuhan Apollo Go Robotaxi)

レイテンシ




強力なクラウド依存が単一障害点 (SPOF) となるリスク。ネットワーク断絶時の車端自治 (Edge Autonomy) と自己復旧能力への要求。

SYSTEM TELEMETRY

医療AI (NVIDIA & Mayo Clinic)

レイテンシ



画像の後処理分類から「生信号からの再構成」へ。REDMODによる既存CT画像からの脾臓がん早期発見（最大3年前）。

統合：AI制約のパラダイムシフト「推論時代のシステム台帳」

SYSTEM TIME: 2024-10-27 15:05:00 UTC

STATUS: OPERATIONAL

モデル単体の賢さ。競争はすでにコモディティ化しつつある。

Agent Runtime、マイクロサービスシャーシ（Wiseの事例：の事例：プラットフォーム化されたガードレールと自動ロールバック）。



タスクの決定論的な部分はシステムが処理し、人間の介入（レビュー、クォリティを最適化する）。

計算コストルーティング、キャッシュ管理、APIゲートウェイ。

タスクの決定論的な部分はシステムが処理し、人間の介入（レビュー、権限承認）を最適化するフロー。

AI実装の焦点は「いかに賢いモデルを作るか」から、「いかに計算リソースと人間の注意力を統治（Governance）するか」へ移行した。



Next Actions: 経営層が注視すべき3つのシグナル

SYSTEM TIME: 2024-10-27 15:10:00 UTC | STATUS: OPERATIONAL ●●●●

[ACTION 1] AI主権とM&Aリスクの監視

Signal: Metaによる中国Manusの買収阻止。

Implication: Agent製品は組織データと知見の集積地。越境M&Aや技術導入において「データ主権」と規制遵守が決定的なビジネスリスクとなる。



[ACTION 2] 評価 (Eval) 帳簿の確立

Signal: 高度なタスク評価コストの急騰と幻覚の残存。


Implication: 単一の客観ベンチマークに依存せず、自社専用の評価用小型モデル (BARRED等) の導入や、粗から精への段階的評価プロセスを構築せよ。



[ACTION 3] RAGデータレイヤーの再構築

Signal: GraphRAGやBlockifyによる検索精度の劇的向上。

Implication: AIのハルシネーション問題はモデル能力ではなくデータの断片化にある。エンベディングの微調整より、ナレッジグラフやデータ構造の最適化に投資せよ。



「デモ駆動」の時代は終わった。今こそ、透明で監査可能な『システム台帳』を構築する時である。