

AI 雷达周报 (2026.04.27 - 05.03)

从「能力狂欢」 走向「系统算账」

本周的数十个产业信号共同指向一个不可逆的拐点：AI 的竞争正式跨越模型能否调用工具的演示阶段。生产级能力不再仅由模型参数决定，而是由 Agent 运行时、评测账本、缓存经济学与系统安全共同定义。

从 Prompt 到 Runtime


持久执行、权限隔离与记忆状态成为基础设施核心。

从订阅制到用量核算


长上下文缓存机制与极低推理成本彻底重塑流量路由策略。

从线上到物理边界

强云端依赖在自动驾驶与医疗场景遭遇真实摩擦，边缘自治成为刚需。




Agent 运行时重构：从会话脚本走向持久执行



记忆与检索重塑

- 告别单一文本摘要压缩。ReaLM-Retrieve 将检索嵌入推理过程而非前置；
- OCR-Memory 将 GUI 轨迹图像化，直接基于视觉历史进行精确溯源。

算力即现金：长上下文与缓存重塑推理路由



DeepSeek V4 的价格冲击

极低的输入价格与缓存命中成本，将高频 Agent 工作流从盲目的订阅模式拉回精细化的按量核算账本，彻底重构企业模型路由决策。


开放模型的反击 (Scale & Swarm)

Qwen3.6 (27B)、Kimi K2.6 与 Grok 4.3 的竞争焦点转移：能否支撑长达数千步的 Agent Swarm 协作，并在极低成本下维持长上下文高精度工具调用。

算力向 CPU 与边缘外溢

基于 1.58-bit 低比特训练 (Falcon-E) 与精细后训练 (IBM Granite 4.1)，小参数展现极高能效比。推理瓶颈扩散至 CPU 沙箱与本地计算资源。

评测危机：算力账本与安全审查的左移



安全与治理左移 (Shift-Left Security)

1. 审查前置: 代码审查 (Claude Security / Cursor) 前置于开发循环。
2. 立体化防御: Prompt Injection 防御从单一机制走向模型层指令分级 (Instruction Hierarchy) + 系统层最小权限与人工确认的双重隔离。


[Cloud-Dependent / 强云端]



单点故障的惨痛教训

武汉萝卜快跑大规模停摆事件，暴露了强云端 Robotaxi 的致命弱点。一旦中心调度或网络链路抖动，车辆无法自救。城市级信任危机要求竞争指标从单纯的测试里程全面转向断网自救与现场接管。

[Edge-Autonomous / 端侧自治]



物理数据的底层重构

医疗 AI (NV-Raw2Insights-US) 摆脱表层图像后处理，深入成像链路，直接从超声传感器原始数据中进行底层信号重建； REDMOD 深入历史长尾数据捕捉提前数年的癌症早期预警。

物理前沿

Google 车载 Gemini 落地，标志 AI 需在低延迟与安全约束下独立运行。

数据主权与并购红线

中国监管叫停 Meta 收购 Manus。Agent 跨境并购不再只是资本游戏，因其沉淀了深度的系统权限与组织知识，AI 主权、数据出口与安全审查正成为落地的核心不可抗力变量。

范式转移：重新定义 AI 技术栈

维度 (Dimension)	过去 (Past Paradigm)	当前与未来 (Emerging Paradigm)	核心驱动力 (Driver)
应用形态	碎片化的聊天窗口与副驾驶 (Copilots)	持久运行、多 Agent 协作的统一 workflow 底座	权限管理 (RBAC)、暂停/恢复执行机制
知识检索	文本向量的分块相似度检索 (Chunk RAG)	知识图谱 (GraphRAG)、视觉记忆 (OCR) 与按需检索	IdeaBlocks 语义结构化、多跳推理需求
成本结构	基于参数量与固定订阅的黑盒成本	精细化的 Token 用量核算与高缓存命中套利	长上下文模型降价、复杂规划与分流执行
质量控制	单一标量奖励与人类感官评测 (Vibe Check)	完整轨迹反思、专用小模型型评估器与多层隔离防御	评测算力开销激增、系统级容错率要求提升

雷达预警：未来 6 个月值得追踪的趋势



具身与车载的物理前沿 (Physical AI Frontiers)

Figure 人形机器人的每小时一台量产验证，标志着物理 AI 的考核标准彻底从演示效果转向产线一致性与高频物理交互的长期可靠性。



知识工作台的入口之争 (The Workspace War)

Codex、Claude Code 与 Cursor 的交互正不可逆地趋同（终端 + 侧栏 + 插件）。未来的超级入口不再再是更更好好的对话框，而是深度绑定企业 API 与历史记忆的智能操作系统。

□ 推理侧的算力外溢 (The Compute Spillover)

AI 的算力瓶颈正从单纯的 GPU 延伸至 CPU、沙箱环境与 Agent Runtime。高频的代码仿真、工具调用与强化学习环境（如 OpenRA-RL）将大幅拉升对通用计算和隔离资源的需求。

行动指南：给团队的架构与工程建议

01



建立显性的评测与算力账本

停止盲目用最強模型做全量测试。根据任务难度实施漏斗分层；利用小模型（BARRED）拦截基础错误，利用缓存策略优化长上下文调用；将 AI 算力视为金融资产进行严密风控（防御 Agent 欺诈）。

02



将系统能力解耦分层

不要将所有扩展动作都粗暴塞进 MCP。理清架构：用 MCP 连接实时系统与数据，用 Skills 沉淀本地操作知识与调试经验，用原生插件打包跨工具的团队约定。让模型专注推理，让运行时负责权限与状态。

03



拥抱灰度与人类介入的混合工作流

放弃对 Agent 100% 全自动化的迷信。借鉴 Kubernetes 的声明式控制器架构，引入信任电池（Trust Battery）机制，将核心审批与高风险决策稳固地交还给人类与业务系统。