


AI 雷达周报 (26.05.04-05.10) : 跨越能力秀, 进入系统责任区

核心断言: AI 正在从“模型能否完成单次任务”的实验室测试全面转入关注“运行边界、评测成本、基础设施与合规治理”的生产系统深水区。

PROCESS FLOW
OPTIMIZATION
BOUNDARY
PROTOCOL



System-Level 系统级重构

- ◆ 焦点: 核心壁垒从 Prompt 转向运行时 (Runtime)。
- ◆ 关键信号: 记忆状态管理、权限边界隔离、后台常驻队列。

EVALUATION
LOAD



COST METRIC
TEST COVERAGE
INDEX

Measurable 评测基建化

- ◆ 焦点: 评测 (Eval) 成为新的“算力瓶颈”。
- ◆ 关键信号: 评测成本指数级飙升、私有化盲测、防篡改测试驱动闭环。

ACTIVATION
COST RATIO
ACTIVATION
COST RATIO
CACHE HIT
EFFICIENCY



SUBSCRIPTION
MODEL
FORECAST

Economical 算力经济账


- ◆ 焦点: 从“参数量竞赛”转向“激活成本”竞争。
- ◆ 关键信号: API 用量计费退潮订阅制、高并发缓存命中率 (Active Params)。

主线一 | Agent Runtime: 从“单次对话”走向“系统常驻”

核心洞察：决定 Agent 表现的不再仅是模型智商，而是它的“运行环境、队列和记忆边界”。


维度	Claude Code 模式 (短进程)	OpenClaw 模式 (长守护)
生命周期 (Lifecycle)	任务驱动 (Task-based) , 单次结束即销毁	常驻后台守护进程 (Daemon + Queue)
核心场景 (Use Case)	开发者本地按需调用的 CLI 工具	接入 Slack / Discord 等长线协作入口
状态管理 (State)	短期上下文记忆	跨会话队列、 全局连接器网关
适用边界 (Fit)	个人提效、 单一代码仓库修改	团队异步协作、 持续监测与触发

CrewAI v1.14 Checkpointing



主线二 | 评测深水区：成为新的算力瓶颈与工程资产


核心洞察：评测不再是简单的“跑分比大小”，而是演变为防篡改、防崩溃的“测试驱动开发（TDD）”。



主线三 | 算力经济学：高并发下的“微操”优化

核心洞察：厂商不再只卷“总参数量（Total Params）”，而是全面卷向“单次推理激活成本”与“前缀缓存命中率”。

Active Params Shift



Infrastructure Acceleration

46倍

前缀缓存（Prefix Caching）：vLLM + Mooncake 将 Agent 前缀缓存命中率推高至 92%，首 Token 延迟下降 46倍。

2倍

多 Token 预测（MTP）：Gemma 4 与 llama.cpp 开始标配，开源模型吞吐量实测突破 2倍。

商业模式映射：API 订阅补贴退潮 -> 转向基于系统真实消耗的“用量计费”模式（如 Anthropic 计费调整）。

主线四 | 深入垂直场景：直面企业环境的“业务摩擦”

核心洞察：企业 Agent 的难点不在模型智商，而在真实的“数据发现、口径治理与验证闭环”。

传统 RAG 的破产



摩擦点：对专业术语、错误码精确匹配效果极差；面对大规模长表查询时召回率断崖式下跌。

新一代混合架构

直接语料交互 (Direct Corpus)：跳过向量化，直接用 grep/bash 访问原始文件系。

经典兜底 (BM25 Fallback)：对于精确词汇重拾传统 BM25 检索算法。

Hybrid Paradigm Path

Success

垂直高责任落地案例 (医疗 OncoAgent)

场景：高责任、零隐私泄漏、全审计链路。

架构解法：

- 双层模型动态路由
- 四阶段 Corrective RAG
- 强制人工介入 (HITL Gate)

将合规验证嵌入架构本身。

信号网络：重塑“AI 操作系统”的拓扑图

核心洞察：模型 API 仅仅是“计算单元 (CPU)”，真正的“AI 操作系统”由全链路生态周边闭环决定。

商业与应用端 (Top Layer)


驱动要素：依赖高并发与低
激活成本带来经济可行性

治理与工程域 (Middle Layer)

驱动要素：Eval 拦截幻觉，
Runtime 控制越界

计算基础设施 (Bottom Layer)

驱动要素：底层速度与成本降低，
决定中层试错与纠错的频率



破局启发：跳出提示词，拥抱系统工程



工程决策 > 模型崇拜 (Incremental Determinism)

心法：停止用单一“最聪明”的大模型解决所有端到端问题。

行动：将非结构化对话提纯为确定性技能（Skill）；用 Eval 验证后，立刻下沉为便宜的小模型、MCP 工具或脚本执行。



后端必须“AI 友好” (Agent-First Backend)

心法：UI 的终局不仅是聊天框。不要让大模型去盲猜复杂的后端接口。

行动：后端必须为 Agent 提供专用的机器可读语义层（如 InsForge 开源原语），极大减少系统猜测幻觉与 Token 浪费。




人机交接是核心功能 (Handoff as a Feature)

心法：在高风险场景中，让人类介入不是“AI 技术的妥协”，而是产品必须交付的“一等公民”功能。


行动：将状态存档、操作审批、可追溯和动作撤销机制设计在应用核心链路中。

下周风向标：持续追踪的关键变量




基础设施落地实测 (MTP Rollout)

追踪 Multi-Token Prediction 在更多开源模型及推理引擎中的代码合并状态，验证吞吐量翻倍的生产级实测数据。



数据 Agent 的企业试水 (Databricks Genie)

观察 Genie 等企业级 Data Agent 能否真正打穿数据字典发现、业务口径对齐与权限隔离的深水区。



极限评测的拐点 (ProgramBench)

持续追踪全量软件重建评测 ProgramBench 的得分变化，观察模型在长程规划与自动测试驱动上的能力破局点。



本地与端侧入口渗透 (On-Device Agents)

关注纯本地化部署（如绑定 iPhone 快捷键离线方案）与桌面系统级整合（如 Perplexity Mac 版）的体验边界突破。