

AI競争の焦点は「賢さ」から「実行ガバナンス」へ

AIレーダー週報：2026-05-11 ~ 2026-05-17

フェーズシフト


単一モデルの能力評価から、長時間稼働、権限統制、インフラ経済性を問う「エンジニアリングとガバナンス」の段階へ移行。

Agentのシステム化

LangChain、GitHub、AWSなどの動向は、AIが「ツールを呼ぶ」段階から「隔離環境・コスト・権限・監査」を伴うマネージドシステムになったことを示唆。

インフラの再評価

稼働率の最適化（GPU 99.4%）やCerebrasの上場など、推論インフラのコストと遅延が次の競争優位を決定づける。



主線1：Agentは管理されたシステム基盤へ移行する

継続的改善と長期信頼性を支えるランタイムの台頭

Evaluation (評価ループ)

Microsoft DELEGATE-52による20回の反復委任テストが示す通り、長期タスクには「意味のドリフト(semantic drift)」を防ぐ診断ベンチマークが必要。



Storage/Memory (専用状態管理)

深いネストや非同期実行の監視に最適化された専用データ層 (例：SmithDB)。



Gateway (コスト/PII/監査統制)

PII保護、コスト上限、APIキー単位の監査をランタイムで強制 (例：LangSmith LLM Gateway)。



Model (基盤モデル)

指示推論とツール呼び出しのコアエンジン。




Environment (隔離実行環境)

モデルが生成したコードやツールを安全に実行するためのOS/ネットワークレベルの権限分離 (例：CoreWeave / OpenAI Windows Sandbox)。

主線2：開発Agentは個人ツールからチームインフラへ

組織ワークフローとレビュープロセスへの完全な統合



主線3：企業RAGが直面する「権限とスケール」の壁


検索精度から、アクセスコントロールとデータ統制への焦点移動

	Prototype RAG（実証実験）	Enterprise RAG（本番環境）
データ規模と精度 (Scale & Recall)	高い検索精度（小規模コーパス）。	EnterpriseRAG-Benchの警告：5Kから500K文書への拡大で、Vector recall@20が90.7%から50.6%へ急落。ハイブリッド検索の必須化。
権限統制 (Access Control)	すべての文書にフラットにアクセス。	Amazon QuickのS3 Knowledge Baseが示す、文書/フォルダ単位の厳密なACL（Deny-by-default）とIAMロール連鎖の必要性。
時間と履歴 (Time & Lineage)	静的なスナップショット。	Graphitiのような「二重時間軸（事実発生時刻と記録時刻）」の知識グラフ。Unity Catalogによるクロスサービスのデータリネージ。

主線4：推論インフラの再評価と極限最適化

利益率を左右するハードウェアの多様化とスケジューリング

Software & Scheduling



Software Optimization (ソフトウェアの限界突破)


非同期バッチング

Hugging Faceが連続バッチングの同期ボトルネックを解消。GPUアクティブ時間を76.0%から99.4%に引き上げ、生成時間を22%短縮。

トラフィック制御

DatabricksのRate Limitingが示す、高スループット環境でのバッチフィードバック型制限（P99レイテンシの改善）。

Hardware Architecture



Hardware Diversification (専用ハードウェアの台頭)

専用アーキテクチャの台頭


NVIDIA Vera RubinがAgentic 推論特有の課題（長いコンテキスト、KVキャッシュの増大）に対し、低ジッターとノード間通信を最適化。

非GPUルートの世界評価

CerebrasのIPOによる約600億ドルの評価。学習性能だけでなく、フロントティア推論のコスト・遅延・供給に市場の需要が近づいているシグナル。

シグナル同士の関係：エンタープライズAIの「自律運用ループ」

孤立したシグナルが形成する、本番環境向けのシステム要件



実務への示唆：本番環境へ向けて今週すべきこと

モデル評価からシステム全体のエンジニアリングへの転換



Design (アーキテクチャ設計)

▶ **Harness (実行基盤) を評価する**
モデル単体 (API) のスコアを追うのをやめる。DatabricksやMicrosoft (MDASH) のように、ツール、権限、検証プロセスを含めたシステム全体でタスク完了率を測定する。

▶ **実行環境を分離する**
プロンプトにエンティションを導入する。プロンプトで「何もしない」よう指示するのではなく、OS/ネットワーク層で**権限を制限したSandboxを導入**する。



Deploy (ガバナンスと統制)

▶ **Gatewayを挟む**
アプリケーションとLLMプロバイダの間に、コスト上限、PIIマスキング、ポリシー違反の監査をリアルタイムで行う**Gateway層を必ず配置**する。

▶ **ACLを再設計する**
企業RAGを導入する前に、フラットなデータアクセスを見直し、ドキュメント/フォルダ単位位の「Deny-by-default」権限を設計する。



Measure (評価と組織定着)

▶ **アウトプットで測定する**
AIの定着度を「トークン消費量」ではなく、チーム単位のアクティブ率や成果物 (PRマージ率、課題解決時間) で測定する。

来週の注目点：次の展開ベクトル

規制領域への進出とインフラのアンバンドリング

高規制領域・垂直Agentの台頭

AnthropicとPwCの提携、Abridge（医療）、Gates Foundationの動きが示すように、コンプライアンス・ドメイン知識・人間による承認フローを内包した金融・医療・公共3向けAgentが実用化フェーズへ入る。

長期タスク専用の評価フレームワーク

MicrosoftのDELEGATE-52に続き、数時間～数日稼働するAgentの「意味のドリフト」や「復旧可能性」を測る、新たな標準ベンチマークツールの出現に注目。

推論スタックのさらなる細分化

Cerebras上場の波及効果として、アロケーター（mimalloc等）、スケジューラ、ネットワーク帯域の最適化など、GPUに依存しない推論経済性の改善競争が加速する。

