



逃离对话框：AI 竞争进入系统工程深水区


本周定调：竞争焦点已正式从单点模型能力转向系统工程底座。



从单次问答到 Runtime 运行时：Agent 状态存储、沙箱隔离与长时保真成为刚需。



从全量知识库到细粒度边界：权限下沉至文档级、账号级，拦截与团队治理成为重点。



从训练算力到推理经济学：吞吐、延迟、调度成为算力层重估的核心指标。

主线一 | Agent Runtime: 从裸奔脚本到自改进闭环

核心挑战：长链路 Agent 需要状态、审计与安全隔离。Agent 平台不再是框架库，而是类似微服务的监控与调度基础设施。



长时可靠性：验证长时委托与 DELEGATE-52 警示

结论：长时 Agent 的评测必须从单题准确率转向多轮操作的语义漂移率。

信息保真度衰减曲线 (Fidelity Decay Curve)



微软 DELEGATE-52 研究现象

❗ 失败模式 (纯 LLM 盲目递归)



- 缺乏状态校验，误差在多步操作中指数级累积。


✅ 成功模式 (Python 工作流平均保真度下降 <1%)



- 注入验证循环 (Verification Loops)：多步骤间加入独立判定层。
- 领域专用工具 (Domain-specific Tooling)：缩小操作自由度。

主线二 | 权限下沉：将 AI 关进企业合规的笼子

核心挑战：AI 系统不能默认全知全能，必须完全映射并匹配人类员工的复杂 IAM 体系。



主线三 | 推理重估：低延迟与高吞吐的极致压榨

核心挑战：Agent 的连续工具调用和海量上下文让推理集群面临极高抖动和低利用率。竞争上移至全局调度。

Pipeline Bottleneck Comparison

传统同步等待
(Traditional)




异步流水线
(Asynchronous)



调度压榨

Hugging Face



异步 Continuous Batching, 用非默认 CUDA streams 解决 CPU/GPU 互相等待。总生成时间提速 22%。

全栈协同


NVIDIA Vera Rubin



将 Agentic 推理定义为综合战：长上下文 Attention、网络延迟控制与 KV-aware 数据交换。

架构异类


Cerebras IPO



市场重估非传统 GPU 架构在巨型参数推理中的延迟优势与 Wafer-Scale 潜力。

产业拼图：数字基建、高危监管与物理世界的殊途同归


底层基础设施的成熟，共同促成 AI 从 Demo 走向业务深水区。



范式转移：从业者的系统构建清单

架构维度	过去 (Chat 范式)	现在 (Agentic System 范式)
评估标准 (Eval)	看模型跑分打榜 (如 MMLU)	看长时保真与回归评测 (Trace-based Eval & 语义漂移)
数据接入 (Data)	文本全量无脑灌入向量数据库	先理清数据血缘、打标签，做极细粒度的文档级 ACL 控制
状态管理 (State)	依靠超长 Prompt 硬塞历史上下文	使用增量 Checkpoint、专门的观测 DB (如 SmithDB) 和独立执行沙箱
成本控制 (Cost)	业务端代码粗放调用外部 API	必须在架构中串联 LLM Gateway, 控制预算、拦截 PII 并路由请求

下周雷达：持续追踪系统演进的边界



基础设施 | Agent 状态层的开源平替



LangChain 的 SmithDB 展现了长任务 Trace 的定制存储需求，观察下周是否有轻量级、高性能的开源中间件跟进填补这一生态位。

评测标准 | 端到端物理时长验证



密切关注其他垂直 Agent（如 Coding、科研）是否开始披露剔除人为干预的真实连续运行 Uptime 数据，超越短时间演示。

企业安全 | 企业级身份链穿透实践



观察后续模型供应商 API 或 MCP 协议，如何进一步传递用户在原有系统里的底层权限 Token，彻底打通跨服务调用的安全审查。