


Agent 跨越模型边界：从单点能力走向生产级基础设施

AI 雷达周报回顾 (2026-05-18 至 2026-05-24)



竞争焦点转移

竞争面已从“模型即产品”全面转向 Model + Harness + Workflow + Economics。

底层共识形成

All Model Labs are now Agent Labs — 模型实验室正在向 Agent 实验室演进。

应用场景跃迁

摆脱聊天框，进入受监管的数据平面、合规边界 (HIPAA) 与自动化流水线。

运行协议化：巨头重构 Agent 生产底座

面向泛终端的 Agent-first 生态

Router Layer: Gemini 3.5 Flash / Gemini Omni

Environment: Managed Agents
(托管沙箱与代码)

Surface: Antigravity 2.0 + WebMCP

整合搜索、办公、移动端入口；模型、IDE 与执行环境被打包为统一接口。

面向企业后端的生级架构栈

API Layer: SageMaker OpenAI-compatible API

Runtime Core: Bedrock AgentCore
(Runtime, Memory, Gateway)

Infrastructure: 双向语音流 +
租户隔离微虚拟机 (microVM)


强调跨会话长程记忆层级切片、细粒度租户隔离、低延迟与严格安全边界。

标准化底座

微洞察： Agent 的启动与调度不再是单次脚本调用，正在像 Serverless 容器一样被标准化、协议化托管（Stateless MCP）。

权限收编：为 Agent 的“手脚”加上审计锁

核心要点：当 Agent 处理真实业务，合规与安全成为最高优先级。权限治理从“静态配置”全面转向“每次工具调用的运行时拦截”。



经济账本：成本、延迟与评测重构

评测维度的系统化 (System-level Evals)


Open Agent Leaderboard

评估完整 Agent 系统而非单体模型。失败任务的试错成本比成功任务高出 20%-54%。



Strands Evals / AgentCore


引入 MLLM-as-a-judge 避免文本代理偏差；引入 Lambda 代码级确定性检查（校验 Schema 与 PII）。



推理经济学的重塑 (Economics of Inference)

价格曲线断崖 (Price Cliff)

DeepSeek-V4-Pro 永久降价 75%。重塑多 Agent 试错协作与长周期任务的可行性边界。



程序化工具调用 (PTC)

AWS 演示通过代码沙箱并行处理与过滤数据，将 Token 消耗陡降 87%-92%。




经济学共识：Agent 的能力不仅取决于模型智商，更取决于试错成本 (Cost of Failure) 与工具调用的编排效率。

拼图合拢：2026 生产级 Agent Harness 架构范式



从业者启示：拥抱“廉价胜任力”（Cheap Competence）




业务流重构法则



工程角色的演化 (Virgin Atlantic)



使用 Codex 的重点不再是单纯“产出代码”。
价值转向：提升测试覆盖率、加速缺陷修复与进行大规模重构（部分 codebase 缩减 78%）。
工程师从打字员变为系统编排者。



医疗与运营角色的演化 (AWS Radiology)



不要用 Agent 替代单一员工，用 Agent 改造整个系统。
不直接替代医生进行诊断，而是利用病历上下文改善放射科疑难病例的分诊调度逻辑。

从业者启示：当单点任务变得极其廉价，人类的稀缺价值完全向工作流的上下游转移——我们需成为能够熟练定义系统架构与最终问责的“市长 (Mayor)”。

下周风向标：值得持续追踪的变量



[基建与冷启动极值]

观察指标：Agent 沙箱的**极速冷启动时间**（如 Daytona 突破的 **60ms** 级别）与 **Stateless MCP** 协议栈的互操作性落地速度。



[专有化小模型的逆袭]

观察指标：**垂直领域模型的反击**。关注如 Dharma-AI 如何在特定企业任务中，凭借领域对齐以 **52 倍的成本优势** 击败前沿大模型 API。



[商业级 Agent 的实体突破]

观察指标：**Google Universal Cart** 及 **UCP 结账协议** 的推进。观察 Agent 如何跨越搜索推荐，真正解决支付、追责与商户清算的实体交易难题。



[端侧与无障碍场景的工程范式]



观察指标：**高风险实体环境下的端侧多模态**。如 Running Guide 等端侧低延迟 **Agent**，**离线响应速度与风险硬分级的优先级** 远高于模型的绝对智力。

资料出处与研究来源

核心分析框架：《AI 雷达周报：2026-05-18 至 2026-05-24》

重点引用机构与研究 - 基础设施层

- **Google**: I/O 2026 产品发布总表、Gemini 3.5 Flash 架构、Antigravity 2.0 及 Search Agents。
- **AWS**: Amazon Bedrock AgentCore 架构、Programmatic Tool Calling 实现、Nova Act HIPAA 合规文档及多模态 Evals。
- **Databricks**: Unity Catalog AI Gateway Guardrails 与运行时拦截策略。

重点引用机构与研究 - 应用与生态层

- **OpenAI**: Codex 企业级案例 (Virgin Atlantic、AdventHealth) 及前沿模型离散几何开放问题研究。
- **GitHub**: Copilot Auto model selection 路由架构及 npm staged publishing 规则。
- **Hugging Face / IBM Research**: Open Agent Leaderboard 及 Ettin Reranker 系列。
- **Latent.Space**: 'All Model Labs are now Agent Labs' 洞察与 AI Infra 市场观测。

本报告旨在过滤噪音，提取高信噪比的系统架构变迁信号。数据均追溯至 2026 年 5 月底官方及核心开发者社区披露。