



AI 雷达周报：单点走向系统


PROJECT:	AI RADAR
STATUS:	ACTIVE
VERSION:	2.6

本周最核心的范式转移：Agent 正在从“模型能力展示（Demo）”全面转向“可验证、可运行、可治理的系统工程体系”。



2026-06-01 至 2026-06-07 | 提纯、综合与前瞻回顾

工程重塑：从 Prompt 到可靠运行时

	Demo Agent	Production Agent
交互形态 (Interaction)	孤立的聊天框 (Chat UI) 	全栈协议集成 (如 CopilotKit / AG-UI 支持共享状态、人类审批流与持久化会话) 
上下文与记忆 (Context & Memory)	短期窗口截断与静默丢失 	原文保真与检索层分离 (如 MemPalace 的可插拔后端存储、Token-In Token-Out 边界控制防污染)
评测标准 (Evaluation)	静态刷榜与单次问答打分 	真实商业沙盒与错误治理 (如 Andon Labs 在带有库存与退款约束的经营任务中暴露 agent 长期记忆崩塌)
容错与环境 (Fault Tolerance)	静默失败、产生脏数据 	强化学习环境基建化 (Bad Envs 治理, 修复 Stale State 与错误 Episode 标记)

引擎升级：长上下文与多模态的系统化

架构
(Architecture)


- **混合架构突破**: Mamba-3 与 Nemotron 3 (Transformer + State Space layers 混合) 成为长上下文效率的关键。
- **超高吞吐**: Qwen3.7-Max 达到**百万 Token** 输入与约 **208.3 token/s** 输出速度。

- **结构化输出**: 多模态走向低延迟与高保真应用。
- **支撑数据**: Surya OCR 2 以 650M 小模型实现多语种版面与表格识别; VibeVoice 达成约 300ms 首次发声延迟。

模态
(Modality)

风险
(Risks)

- **微调泄露**: CMU/Columbia 论文验证, Fine-tuning 会导致已对齐模型重新复现预训练记忆 (最高生成 85-90% 的受版权保护原著文本, 单段超 460 词)。




落地深水区：流程重构与成本治理



预算与治理红线

Token Metering 时代：微软 Copilot 转向基于 Token 计费。
AI 补贴时代收紧，成本治理（多模型路由、预算权衡）正式成为架构师必修课。



安全基建：从模型卡到外部链路

内层：模型自身对齐 (Fragile Alignment)

系统提示词与偏好对齐更像“脆弱过滤层”，易被越狱或微调击穿。

中层：研发链路闭环 (The Dev Loop)



Anthropic 报告：超过 80% 合入代码可归因于 Claude；工程师合入量达 8 倍，小型优化实验加速 52 倍。


瓶颈：风险在于验证、审查和组织瓶颈是否能跟上模型的“自我进化”。

外层：产业链与黑灰产 (Supply Chain & Grey Markets)

实体拦截：OpenAI 等头部实验室联合施压，要求对 DNA 合成订单进行强制买家筛查（防范生物武器设计）。

API 灰市：账号农场与代理路由带来的数据外泄、模型降级与输出不可验证风险。

化学反应：三维共振



行动指南：技术管理者的 3 个转变



预算视角：从“盲目堆大模型”转向“多模型路由与精算”

应对 Token Metering 时代。停止对所有任务调用旗舰 API。建立内部路由，将简单操作下放至本地轻量模型，旗舰模型仅负责复杂决策。



架构视角：从“手写 Prompt 链”转向“标准化基础设施”

停止维护脆弱的 Prompt 代码。必须在团队级建立独立的“记忆层”、“检索层 (Retrieval Layer)”与“MCP 技能库”，彻底分离上下文与业务逻辑。



测试视角：从“单次问答跑分”转向“真实约束沙盘”

将 Agent 评测基建视为核心资产。构建包含成本、失败惩罚、API 延迟和业务灰区的模拟沙盘环境（如引入 Andon Labs 的长期经营评测理念）。

下周雷达：待验证的系统盲区


产品关注

转化与客诉：社交平台（Meta Business Agent）将 Agent 全面接入商家核心业务流后，带来的真实交易转化率与客诉率数据。

基建关注

算力资本账单：AI 算力基建带来的债务与资本开支压力（关注大厂回购节奏暂停带来的多米诺效应与算力重定价）。

重要性 (Importance)



工程关注

记忆陈旧与崩溃：Agent 长期运行中的历史上下文污染，自动化工具（如 MemPalace、OpenAI dreaming memory）在实测中的表现究竟如何？

合规关注

记忆泄露修补：开源模型在应对 Fine-tuning 导致预训练版权文本泄露上，会推出哪些系统级修补方案？

紧迫性 (Urgency)