


【本周定调】从“单点魔法”到“可靠系统”

Agent 工程跨越分水岭 —— 走向可评估、可控成本与可真实执行的架构。




核心论断：Agent 已超越单纯的大模型包装。Harness（运行控制层）、权限边界、长程评测与成本治理，正式成为构建 AI 系统的核心护城河。

主线一 | Agent 工程：构建可运行的闭环底座

可靠性来自系统结构，而非更长的 Prompt。

核心洞见 (Key Insights)

- **验证重于生成**：任务完成不再由模型自我声明，强制依赖外部 Checker 与测试管线闭环。




- **告别盲目读取**：预索引图谱大幅降低 Token 浪费，只读取结构化关联代码。



- **代码级规范**：System prompt 演变为 instructions.md，Agent 走向可读协议化开发。




三层式架构图谱 (Isometric Cross-Section Layered Architecture)



80%

主线二 | 模型与评测：向「真实执行面」施压

评测防作弊，前沿筑门控，推理拼路径。



评测维度（长程真实考验）



从单题作答转变为按天/小时计的长程闭环。



OSWorld 2.0: 1.6小时人类工作量, 318次调用



METR: 长达11.3小时 Horizon 测试

防数据污染成为新标准




门控维度（前沿溢出控制）




高风险能力发布内置实时分类器，不再追求无门槛发布。




GPT-5.6 预览分层:
Sol / Terra / Luna




先向可信伙伴与政府披露




推理维度（系统级成本博弈）



从卷参数转为卷系统服务路径 (Serving Path)。



Multi-Token Prediction
后置改造




DFlash
推测解码提升吞吐

大小模型路由成为成本优化刚需

主线三 | 组织采用：AI 离开聊天框，接管业务中枢

采用门槛不再是能力，而是预算、权限与职责重构。



信号共振：为何一切都指向「Harness」？


模型能力、开发者生态与企业合规在此交汇。



核心价值： Harness 填补了模型与现实世界的断层，负责组合工具、圈定权限范围、管理长期记忆与执行容错。
产业断言： 竞争重点正在从单次神奇提示词全面转向完整的 Harness 系统工作台。

从业者启发：从“提示工程师”到“Agent 团队经理”

工具链变了，人和 AI 的分工必须跟着变。



下周雷达：三大关键演变追踪

保持敏锐，寻找工程落地的真实数据点。



[追踪坐标 1]

防作弊长程评测的共识演进

观察点：OSWorld 2.0、METR 等数小时级别评测是否会成为新行业标准？在数据污染危机下，模型厂商将如何自证其长程可靠性？



[追踪坐标 2]

“上下文压缩工具”的真实 ROI

观察点：CodeGraph（预索引图谱）和 TencentDB Agent Memory 在真实的、高频的企业业务中，究竟能挽回多少 Token 成本并降低多少时间延迟？



[追踪坐标 3]

前沿模型门控的溢出效应

观察点：随着 GPT-5.6 加固访问门控，闭源巨头与开源阵营的摩擦加剧，全尺寸开源生态是否面临断层？中小团队将如何调整模型依赖？