


AIレーダー週報：単なる 「タスク実行」から「運用 可能なシステム」へ


2026-06-29 ~ 2026-07-05 | The Maturation Arc

今週の結論 (Executive Summary)

Agent Engineeringは、「ツールを呼べるデモ」の段階を終了した。今週のシグナルが示すのは、評価可能で、デプロイ可能で、ガバナンスの効く「プロダクションシステム」への移行である。モデルの性能競争から、システム全体での信頼性・コスト・権限管理の競争へとパラダイムが完全にシフトした。



Thread 1: Engineering — 単一プロンプトからシステム・ライフサイクルへ




Andrew Ngの「3つのフィードバックループ」：分単位のAgentループ、時間単位の開発者判断ループ、外部ユーザーの製品ループ。モデルは速いが、システム全体の設計とリズムは人間が規定する。

Thread 2: Evaluation — 1次元のスコアから多次元のワークフロー制約へ

	 Leaderboard Era (ベンチマーク至上主義)	 Workflow Era (ワークフロー適合性)
評価軸	単一のペーパーテストスコア (暗記重視)	検証可能な報酬 (Verifiable rewards) と ドメイン特化の判断力 (例: GRPO, GeneBench-Proの分析パス選択)
コスト意識	入出力のトークン単価のみ	タスク完了までの総コスト (Agentのターン数、 キャッシュ挙動、フェイルオーバー経路を含む) (例: Sonnet 5 vs Fable 5の比較)
失敗の扱い	不正解としてスコア低下	自己修正のループ、フォールバック、人間への 委任 (Human-in-the-loop) の安定性


最新モデルの選定基準は「誰が最も賢いか」ではなく、「ターゲット業務において誰が最も安定的で、安価で、検証可能か」に移行している。

Thread 3: Tooling — 人間用GUIから「Agent-Readable」なエコシステムへ




ツールの焦点は「チャット画面の拡張」から、Agentが確実に操作・観測できる「標準化されたインターフェース層」の構築へ移っている。

Thread 4: Enterprise — 「ライセンス購入」 から 「組織・ガバナンスの再設計」 へ



導入の成否はモデルの性能ではなく、予算、調達、SOP（標準作業手順）、プロセスオーナーの再定義にかかっている（例：SierraのAgent Engineerロール）。

Synthesis: 相互強化する4つのシグナル (The Maturation Flywheel)



これらは独立したニュースではない。ツール、評価、エンジニアリング、エンタープライズ要件が「自己強化ループ」として回り出し、AI産業全体を機械的・工業的なシステムへと押し上げている。

実務への示唆 (Implications for Practice)

✕ 巨大で複雑な単一のプロンプトにすべてを依存する。

✕ リーダーボードのスコアや発表時の宣伝文句だけでモデルを選定する。

✕ Agentに人間のための複雑なGUIを強引に操作させる。

✕ ミッションクリティカルな業務を単一のクラウドAIベンダーに完全に依存する。

✓ 役割、コンテキスト、ツールを分離し、再利用可能な「Skill」パッケージとしてモジュール化する。

✓ 自社の実ワークフローにおける「タスク単価（ターン数含む）」と「失敗時の回復力」を計測する。

✓ MCP（Model Context Protocol）や専用APIなど、機械が確実に読み取れる構造化インターフェースを提供する。

✓ アカウント停止やポリシー変更に備え、フェイルオーバー経路とローカルのフォールバック実行環境を設計する。

来週の注目点 (Next Week's Radar)

オーケストレーション層の進化 (Model Orchestration)

Sakana AIのFugu/Fugu-Ultraのような、タスク分解・モデル選択・ツール実行を統合するルーティング・レイヤーの台頭に注目。単一モデルの優位性は薄れる。

ツールプロトコルの標準化 (Protocol Standardization)

Chrome DevTools MCPやAgentSkillsなど、Agentが環境とやり取りするための「標準規格」の普及速度。エコシステムのロックインを左右する。

エンタープライズ・ガバナンスとアイデンティティ (Governance & Identity)

Proof of Human (人間の証明) やOpenAIの規制提案など、Agentによる代理実行時の権限管理、監査ログ、匿名性確保のフレームワーク形成を追跡する。

The focus is no longer on what AI can do, but on how we govern what it does.