


今週の結論：単一能力から「運用システム」への移行



Agent Engineeringの成熟

モデルを「呼ぶ」段階から、観測・追跡・監査が可能な実行システムを運用する段階へ。

コスト構造の変化

最適化の焦点は、100万トークンあたりの単価から「タスク完了あたりの実コスト (Useful Work per Dollar)」へ移行。

物理・法規制との衝突

ソフトウェアの枠を超え、データセンター（電力・水）や連邦安全基準など、現実世界の制約レイヤーに到達。

Agent Engineering：アーキテクチャと統制ループ

Agent Loop Governance Matrix

1. Turn-based

[Trigger] Human Input
[Governance] Human-in-the-loop
[Handoff] High

2. Goal-based

[Trigger] Goal & Budget
[Governance] Verifiable Reward
[Handoff] Medium


3. Time-based

[Trigger] Cron/Schedule
[Governance] State Check
[Handoff] Low

4. Proactive

[Trigger] Event Triage
[Governance] Pre-execution Guard
[Handoff] Exception Only

ByteByteGo Handoff Model



LLM Routing & Caching：タスクごとの「Model Affinity（モデルの固定）」と「Static Prefix（不変プロンプトの先頭配置）」が、キャッシュヒット率と実コストを決定する。


Confidence Threshold：カスタマーサポートの自動化の壁は、モデルの回答能力ではなく、責任境界とエスカレーションの閾値設計にある。

Model & Evaluation : スケール・制御・リアルタイム検証

[1. Open Scale]

Kimi K3 & Inkling

Kimi K3 (2.8Tパラメータ、1Mコンテキスト) と Inkling (975B MoE) 。オープンモデルの主戦場はチャットから、マルチモーダルと長距離コーディングへ。



[2. Reasoning Control]

SparDA & Effort levels


推論の「深さ」がUI設定から制御パラメータへ。SparDA等によるKVキャッシュの先読み (Forecast projection) が長文スループットを劇的に改善。




[3. Automated Eval]

GPT-Red & Verifiers


OpenAI GPT-Redによる自己対戦型の自動レッドチーム化。評価は静的なテストから、持続的な「自己プレイ強化学習」と「実行時検証」へ移行。



Toolchain : 知識アセットと再利用可能なワークフロー



Industry & Gov : ソフトウェアからインフラ・政策の境界へ




Synthesis : 新しいエンタープライズAIスコアカード

トークン単価の錯覚

安価なトークンは低コストを意味しない。失敗の再試行、人間の確認、運用パッチが真のコストを決定する。

ROIの再定義

OpenAIのScorecardやCars24の運用事例が示すように、評価軸は「モデルが何を作れるか」から「1ドルあたりいくつのタスクを完了し、人間へ安全にハンドオフできたか」へ。



来週の注目点：Next HUD Coordinates

[Coordinate X: Office OS]

コーディングエージェントから汎用 Office OSへ：Cursor Sandの動向。エンジニアリングで培われた文脈管理が一般業務へ拡張されるか。

[Coordinate Y: Semantic Metadata]

意味的メタデータの標準化：apache/ossie等。BI/AI間のメタデータ交換が、データエージェントの必須インフラになる。

[Coordinate Z: Hardware Entry]

新しいハードウェア参入：Roblox Buildによるゲーム生成とAIコンソールの進化。入力インターフェースがソフトウェアツールを迂回する動きに警戒。