

告别盲目调用，建立系统纪律

2026-07-13 至 2026-07-19

本周定调：Agent 工程全面告别“调用更强模型”的盲目期，转向“经营可持续的任务运行系统”。

01

焦点迁移

真正的竞争点已从单次回答的聪明度，迁移到长期任务的治理。

02

成本真相

评估指标全面转向真实成本控制（含重试、人工复核与缓存命中率）。

03

运行准则

平台正加速构建系统的可审计性与物理/合规边界。

RAW MODEL CORE

GOVERNANCE SHIELD

ROI LIMITS

NORMFLOWP

ROI LIMITS

HARNESS FRAMEWORK


架构演进：从“单次调用”走向“运行套件”

过去的单次调用



上下文易中断，计费高昂

现在的 Agent Harness



LLM Routing 的真相：关键不在于次次换模型，而是“按任务保持模型亲和性 (Model Affinity)”，避免打断上下文缓存。

Agent Loop 拒绝盲目循环：
演化为四类可控模式

回合制 (Turn-based): 需人类逐轮确认	目标驱动 (Goal-based): 需明确成功条件与预算
周期性 (Time-based): 固定周期与状态追踪	主动防御 (Proactive): 事件触发的自动修复

Prompt Caching 成为纪律：
静态前缀（系统指令、工具）与动态尾部严格分离，Session设计必须围绕 Cache Hit Rate 展开。


模型前沿：万亿规模破局与推理精细控制



规模与上下文极限

- Kimi K3 (2.8T参数) 与 Inkling (975B MoE) 将开放权重模型推向万亿级。
- 原生支持多模态与百万级 (1M) 上下文的长程任务。

Reasoning Effort



推理强度可控化

- 推理计算不再是黑盒，而是演变为 API 中的“连续控制量”。
- (如 SparDA 使用 Forecast projection 预取长上下文 KV blocks, 平衡长推理与吞吐)。



实时交互架构分层

- GPT-Live 与 Mercury 2 展示新趋势。
- 前台极速语音双工，后台异步深度推理。物理分离解决延迟与深度的矛盾。

工具生态：工作流的全面资产化与可复用

散落的代码与提示词

Processing Stations



MCP 应用化 (App-ification)

案例: FineTune Studio, mcp-use

MCP 从单纯的“工具调用协议”扩展为全栈应用框架，收束模型训练、UI、权限与日志边界。

Skill 封装与审计

案例: Hermes bundles, Hallmark

技能从个人提示词片段，升级为可安装、可复查（如 Hallmark 的 57 个设计规则门控）、可版本管理的工程包。

记忆图谱化


案例: Graphify, Graphiti

抛弃单纯的向量片段，转向带有时间维度 (Temporal) 和关联链路的本地代码与事实知识图谱。

产业洗牌：重估真实 ROI、硬件入口与合规底线



信号穿透：三轴联动的 Agent 闭环



【1】产业约束触发工程重构

产业对真实 ROI 和“Cost per Task”的严苛要求，直接催生了工程层面对 Prompt Caching、Task-level Routing 的系统性依赖。

【2】工程套件规训模型行为

运行套件（Harness）的成熟，迫使模型侧将推理强度（Reasoning Effort）、自动红队（GPT-Red）做成可控的系统 API，而非盲目输出。

【3】全局演进终局

孤立的“强模型”失去溢价。未来的胜者是能将模型、MCP 界面、可追溯记忆和治理边界打包成一个完整操作系统的平台（如向通用 Office 扩张的 coding agents）。

破局启示：抛弃 Demo 思维，拥抱工程纪律

⚠️ 过去的 Demo 思维

✅ 现在的工程纪律

成本核算

简单对比大模型 API Token 价格

计算包含失败重试、缓存未命中与人工复核的总任务成本 (Cost Per Task)

应用开发

堆砌无限循环的 Prompt 与黑盒黑魔法

设计具备明确停止条件、带审计界面与文件沙箱的 Agent Harness

工具沉淀

收集散落的魔法提示词片段

构建基于 MCP 和 Spec 的可版本管理 Skill Bundles

安全防御

仅在 Prompt 中口头告诫模型“不要删库”

在 Hook/Shell 层（如 destructive_command_guard）执行强拦截与网络出站审计

下周锚点：值得持续追踪的边界信号

● 开放模型的企业部署大考

Kimi K3 等万亿级开放权重模型在真实企业 Harness 中的落地稳定性与真实显存占用表现。

● Agent Sandbox 的标准化

关注具有文件系统隔离、状态恢复和权限边界的容器化运行时的演进。

● 硬件与 Agent 的深度融合

类似 Codex Micro 的物理外设，是否会引发新一轮办公场景交互设备的爆发，重塑交互入口。

● 联邦级 AI 监管的实质拦截

美国州级 Frontier Safety 标准向框架的收敛进度，及其对新一代模型发布前的实质拦截效应。