

AI Engineering の競争軸は 「生成能力」から「検証可能な運用システム」へ

AIシステムの価値を決めるのは、単発のモデル性能ではなく、
結果を安全かつ確実に納品できるアーキテクチャの有無である。

Verifiable Production System
(検証可能な運用システム)

Model Capability
(生成能力)

1. Control Plane & Verification

独立した検証プロセス、
テスト、監査ログが
新しい防壁となる。


2. Orchestration & Routing

単一モデルへの依存から、
コストと特化領域に基
づくルーティングへ。


3. Real-World Accountability

物理世界や既存システム
への介入が求める「同意・
可逆性・説明責任」。

主線 1：検証とコントロールプレーンが新たな防壁となる



主線 2：単一モデルから「コスト・特化・ルーティング」の協調アーキテクチャへ



Branch 1: High-Efficiency / Low-Cost (高効率・低コスト)

GPT-5.6 (Luna: -80% cost) や
Inkling-Small (12B active parameters)。
日常的な実装・テスト・評価を低コスト
で処理。

Branch 3: High-Reasoning (高度な推論)

GPT-5.6 Sol (API連携による実行コスト20%削減) による複雑なプランニングと最終検証。数学的証明 (Lean certificate) などの厳密なタスク。

Branch 2: Specialized Domain (専門領域特化)

MAI-Cyber-1-Flash。特定のセキュリティタスクの90%を自律処理し、難易度の高い10%のみを上位モデルへルーティング。

主線 3: 実世界への介入が要求する 「同意・可逆性・説明責任」

Center: Digital Action (デジタル空間の行動)

Google Search AI Mode: カレンダー参照、在庫確認の電話、予約実行。

要件: データ最小化、最終確認、実行の可逆性 (Reversibility)。

Middle: Physical Action (物理世界での協働)


Gemini Robotics ER 2: 継続的動画認識によるタスクの進行判断、複数ロボット間の状態共有。

要件: 低遅延のオーケストレーション、人間による緊急停止 (Kill switch/Stop control)。

Outer: Regulatory / Societal (社会・法規制)

EU AI Act対応、UAEの裁判所システム導入、カンボジアの詐欺ネットワーク遮断。

要件: 透明性、来歴管理 (Provenance)、専門職による最終判断、プラットフォーム間のシグナル共有。



3つの主線が構成する 「新しいAIシステムスタック」

Middle Layer: Multi-Model Routing & Execution (実行とルーティング層)

タスク分業 (オーケストレーターとエグゼキューター)。

評価軸：トークン単価ではなく「結果に対する総合コスト (Cost per outcome)」。

Critical Insight:

Anthropicのサイバー評価での意図せぬ外部アクセス事例が示す通り、隔離環境と厳格な権限管理が必須。

Top Layer: Real-World Actions & Enterprise Outcomes (実社会への出力層)

物理的介入・企業導入 (Univéの保険業務、Simileの人口シミュレーション)。

ガバナンス要件：人間の最終責任、同意プロセス、来歴管理。


Foundation Layer: Control Plane & Verification (検証と制御の基盤層)

全ての土台。独立した監査ログ、ツール実行の幂等性、ネットワーク分離。

実務への示唆：次世代AIシステム構築のためのアクションプラン

	From (Era A)	To (Era B)
Focus (評価指標)	Output Generation (単発の生成品質・トークン価格)	Outcome Cost & Audit (目的達成までの総コストと監査可能性)
Architecture (アーキテクチャ)	Single Best Model (最強の単一モデルへのプロンプト入力)	Routable Multi-Model (適材適所のルーティングと判断の委譲)
Risk (リスク管理)	Prompt Injection (プロンプトによる出力制御)	Network Isolation & Idempotency (ネットワーク分離、冪等性、承認ゲートによる制御)
Value (組織的価値)	One-off delivery (個人のスキルによる単発の納品)	Reusable skills / workflow (インストール可能なスキルと組織的ワークフロー)

来週の注目点：監視すべき3つのシグナル



Blip 1: Control Plane の標準化

ベンダーロックインを防ぐ、モデルに依存しないオープンな監査・実行ハーネスの普及。

Blip 2: Multi-Agent Workspace の進化

人間とエージェントが権限と履歴を共有するコラボレーション空間（OpenWork, Buzz 等）のエンタープライズ導入。

Blip 3: Independent Evaluations（独立機関による評価）

DeepSeek V4-Flash や Kimi K3 など、相次ぐ新規オープンモデルに対するサードパーティの厳密な実用性検証の動向。