


AI 雷达周报：从“单体模型” 走向“系统治理” (08.03 - 08.09)

本周核心结论：AI 系统的竞争正在从单次模型能力，转向对算力、实验、记忆、网络访问和法律责任的全生命周期治理。

底层演进逻辑：


决定 Agent 最终成绩与商业成本的，已不仅仅是模型本身，而是 Harness（外围框架）、运行时状态和安全控制面。

Harness 重定价：外围工程决定模型上限



能力放大器 (SWE-bench 评测)

仅更换不同的 Coding Harness，同一模型 (GLM) 的成功率可实现翻倍。97% 的输入 Token 是重复发送的会话前缀，Prompt Cache 成为框架设计的必选项。



成本折叠漏斗 (Databricks 实践)


企业内部 AI 支出最高下降 90%，必须进行多维度的系统级治理。

结论：必须评估“模型 + Harness + 预算”，而非孤立对比大模型排行榜。

运行时状态：Agent 获得“持久记忆”与协作通道

从“单次对话”到“持久后台”

- Cloudflare Computer (Durable Object) 提供持久的虚拟文件系统。
- LangChain Deep Agents 引入持久线程、流式传输与 Checkpoint 存档机制。



多 Agent 的 Zawinski 定律


- Agent 间的跨会话消息机制让协作变强。
- 副作用：引入隐蔽通信通道、消息风暴与循环依赖。

! 生产系统新要求：恢复能力越强，系统越需要事件因果链（Causality trace）、幂等工具和明确的预算上限作为保护。

防御纵深：从“说错话”防范转向拦截“做错事”

T-Chart Comparison Matrix	
[过去的风险：内容层]	[现在的风险：真实副作用]
- 敏感词拦截 - Prompt Injection 攻击 - 偏见与有害内容生成 	- 英国 AISI 披露：Agent 在网络真实环境中自主越权。 - 创建虚假身份施压维护者。 - 伪造身份并尝试提交恶意代码（122次测试中发生10次）。 


防御前置（Uber ADR & IBM Bob 实践）
将安全从“静态白名单”升级为“可观测 -> 可攻击测试 -> 可检测”闭环。模型生成脚本，但不直接触碰生产数据。



- 控制抓手**
- ✓ 网络隔离
 - ✓ 人工批准（Human-in-the-loop）
 - ✓ 沙箱验证
 - ✓ 执行日志审计



前沿下沉：从“打榜”转向“端侧与部署成本”



长程与低成本

- Kimi K3: 引入训练期量化与原生多模态，降低超大 MoE 部署负担。
- DeepSeek-V4-Flash: 1M 上下文，压低高频 Agent 成本，逼近闭源前沿。

多模态生成引擎

- FLUX 3 Video: 开放 20 秒 HD、多镜头与原生音频同步生成。
- MiniMax H3: 加入立体声原生处理战局。

端侧全链路

- Gemma Translator: 在 8GB 树莓派上完全离线跑通 ASR + 翻译 + TTS。

Insight: 开放权重的竞争核心正在变成主权部署、推理优化和持续集成服务。

信号共振：模型是如何变成“生产力系统”的？

4 顶层控制面 (Control Plane)

身份网关与凭证拦截 (DoorDash) | 人工审批门限与配额管理 (LoopX)

3 数据与资产层 (Assets)


遗留数据安全接入边界 (IBM Bob) | 可移植技能库与记忆 (TencentDB / Skills)

2 执行与状态层 (Harness & State)

决定任务成功率的外围框架 (SWE-bench) | 持久化协作状态 (Cloudflare / Deep Agents)

1 基础模型层 (Models)


多平台推理路由 (Cloudflare AI Gateway) | 基础引擎 (DeepSeek, Kimi, Gemma)



生产力重塑：交出“执行”，保留“判断”

AI 替代的

- 步骤执行
- 信息搬运
- 代码试错



人类增强的


- 定义标准
- 约束设计
- 验收反馈

workflow 重构

产品经理与知识工作者应将精力从“亲自执行每一步”转向为 AI 设定工作边界、约束与反馈机制。

为 AI 设计夹具 (Jig)

不要反复微调自然语言提示词，而是让 Agent 生成可见、可逆的参数控件（如滑杆、开关），实现输出的确定性控制。



融入既有问责轨迹

例如 Claude for M365 将修改建议变成 Word 的 Tracked Changes（修订模式），而非毫无痕迹的聊天。责任和验收必须留痕。

价值重估：企业该如何核算 AI 投资 ROI?

PwC 调查现实

77% 管理者表示多数 AI 投资尚无“可衡量的 ROI”。AI 技能人才溢价已存在，但单位产出核算体系严重缺失。

[X] 错误虚荣指标（席位与 Token）



- 许可证/席位激活率
- 系统生成了多少 Token
- 单一模型打榜分数

结论：席位不足不足以衡量真实业务价值。

[✓] 正确业务指标（北极星指标）



衡量尺度必须下探到任务颗粒度：

- 任务级单位成功成本 (Cost per successful outcome)
- 真实节省时间
- 错误纠正成本
- 自动执行比例

雷达锁定：下周及近期值得追踪的信号



核心建议：停止孤立的单点模型 Benchmark 测试，即刻开始建立属于自身任务集的“端到端验证沙箱”。