


AIは「単体モデルの呼び出し」から 「統治可能なシステム実行」へ




エージェントはツール呼び出しを終え、**ポータブルな動的ランタイムの構成フェーズ**へ突入。

システムの評価基準は「**システム全体のアーキテクチャの堅牢性**」へと完全に移行。

キャッシュ効率、来歴証明、実世界での副作用の封じ込めが、**真のビジネス価値**を決定づける。

固定スクリプトから「動的ランタイム」への移行



フックによる動的構成

タスクの各ターン前にスキルやサブエージェントをReactのフックのように動的に読み込む手法が台頭。

ポータブルな標準規格

ベンダー中立なパッケージ仕様により、プラグインの移植性が飛躍的に向上。


新たなサプライチェーン問題

開発の摩擦が低下する一方、フックの順序、依存関係、実行権限、ロールバックが新たな設計課題に。

スケールの限界を決める「協調メカニズム」と「実世界の副作用」

“Friction Model” (Anthropic Experiment)

マルチエージェントの衝突と機能不全



中央指揮のない環境では、高い単体能力があってもシステム全体が機能不全に陥る。


“Containment Model” (Always-on Agents)

常時稼働エージェントの統治と封じ込め



機械的な速度でシステムの間隙を探す脅威に対し、明示的な所有権とエスカレーション条件のハードコードが不可避。

単一トークン単価から「エンドツーエンドの実行効率」へ



導入価値の源泉は「ワークフローの深さ」へ

検証・編集可能な成果物の生成 (Editable Artifacts)

Model MLの事例：文字列ではなく、承認フローに乗る構造化データ (PPTX/Excel等) を出力する責任。

エンタープライズ・データループ

本番環境のトラフィック (Production Traffic)

利用上位10%の企業は典型企業の8.3倍のトークンを消費し、業務プロセスに深くモデルを組み込む。

失敗ログと例外の抽出 (Hard Negative Extraction)

本番環境の失敗を抽出し、AIシステムの弱点を特定する監視の仕組み。

専用モデルへの継続的重み反映 (Dedicated Model Update)

Shopify Sidekickの事例：毎日ログを圧縮・反映させ、推論コスト削減と精度向上を両立。

シグナルの統合：モデル中心から「システム統治」へ

	【旧パラダイム】モデル中心	【新パラダイム】システム統治
実行 (Execution)	単発のモデル呼び出し (Single Call)	動的プラグインとフックによる ランタイム構成
安全 (Safety)	有害コンテンツの生成拒否 (Content Refusal)	実世界の副作用と権限の封じ込め (Containment)
性能 (Performance)	トークン生成速度と単価 (Token Speed/Price)	E2Eレイテンシとキャッシュ効率 (End-to-End Latency)
価値 (Value)	ライセンス導入数 (Seat Count)	ワークフローの再利用性と専用モデル化 (Workflow Depth)

開発、セキュリティ、ビジネスの全領域において、焦点は「モデル内部の能力」から「モデルを包み込むインターフェース、権限境界、データループの設計」へと完全にシフトしている。

今すぐ見直すべき4つの境界設計



1. 権限と隔離 (Permissions & Isolation)

動的プラグインや常駐エージェントに対し、最小権限 (Least Privilege) の原則と不可逆操作前の承認ゲートを強制する。



2. 完了条件の再定義 (Completion Criteria)

モデルの「自己申告」をゴールとせず、テスト通過、レビュー、成果物の構造化、人間の承認をタスク完了の絶対条件とする。



3. 共有リソースの管理 (Shared Resource Governance)

複数エージェント間の「リソース競合」や「ロック」を防ぐため、所有権の明文化と競合解決プロトコルを実装する。



4. 例外・エスカレーション経路 (Escalation Paths)

「ブロック状態だがシステムエラーではない」ケースを検知し、安全に人間のオペレーターへ引き継ぐ基準をハードコードする。

次期フェーズに向けたウォッチポイント

プラグイン仕様のデファクト化 [Standardization]

Agent Plugins 1.0などのディレクトリ仕様やMCPが、クライアント間でどこまで互換性を確立し、エコシステムとして定着するか。

実行環境のハイブリッド化 [Local vs Cloud Routing]

ローカル実行モデルとクラウド実行の境界線。データプライバシー要件に応じた動的ルーティング技術の成熟度に注目。

推論・学習のハードウェア分業 [Hardware Differentiation]

TPUの分岐に見られるように、スループット（学習）とレイテンシ（推論）に特化した専用ハードウェアの使い分けがもたらす実コストへの影響。

