


从“卷模型”到“建系统”

2026年8次第3周 AI 雷达回顾

模型正在成为可替换的标准组件。
真正决定 AI 成功率、成本与安全边界的，是**模型之外的系统厚度**。



[能力] 演进

从“模型原生参数”
→ 转移至“外部 Harness 控制面”

[成本] 演进


从“Token 表面标价”
→ 转移至“端到端推理供应链”

[落地] 演进

从“一次性惊艳演示”
→ 转移至“可审计的闭环工作流”

主线一 | Harness: 接管人类注意力的生产控制面

Spectrum Diagram



生产环境必备要素




主线二 | 算力账单的“冰山模型”



核心准则：单一 Token 降价 ≠ 降本。必须按“完整任务轮次”与“缓存命中率”核算端到端总成本。

主线三 | 安全验证：从“拒绝回答”走向物理与现实闭环



主线四 | 重塑企业 workflows: 可量化的工程杠杆

遗留代码重构 (Asana)

产品内容矩阵 (Stampli)

交付压缩的黄金法则

- ✓ 1. 极窄的任务定义
- ✓ 2. 严格的隔离并行
- ✓ 3. 接入唯一数据真源
- ✓ 4. 逐项人工审查批准

过去: 5 年

过去: 243 小时

现在: 1.5 周

现在: 77 小时



成本: 1.2万美元 /
4个隔离 Codex 代理



接入真实上下文库




STRICT REVIEW



统一过滤阀门: 人类审核 (Human Review)

信号织网：AI 系统的真实 ROI 方程式



落地启发：从业者的能力矩阵转移

过去范式



评测并挑选参数最强的模型



编写极尽详尽的 Prompt



盯紧单次 Token 标价与配额



枯燥内容的首稿创作者



当前与未来核心



设计精细的权限、上下文与内存路由



定义严格的工具契约、回滚机制与事件日志



建立全域产品可观测性与任务级成本归因



核心问题定义者、边界审查者与最终负责人

持续追踪：下周观测雷达与锚点



【技术与架构】分发层整合之战

- 关注 Cursor Origin、OpenRouter 与各大 IDE 如何进一步争夺 Agent 托管权。
- 观测点：代码上下文控制权是否会完全向本地与专属工作流倾斜。



【算力与基础设施】实体资源交付约束

- 关注从 GPU 向外蔓延的资源瓶颈。
- 观测点：高带宽内存（HBM/DDR5）现货价格波动、机房电力交付周期与液冷产能。



【治理与合规】责任延伸与模型撤销

- 关注 Meta 青少年安全案判例走向。
- 观测点：平台责任是否从内容下架延伸至界面机制设计，以及删除特定训练数据在法律层面的实际可执行性。